

LAPORAN *PROJECT MACHINE LEARNING*
KLASIFIKASI PENYAKIT GENETIK MENGGUNAKAN
ALGORITMA *MACHINE LEARNING* PADA *GENETIC DISEASE*
PREDICTION DATASET



Oleh:

1. Azra Dita Nurcahyati (K1D024041)
2. Nayla Edenine Qohar (K1D024044)
3. Aura Salsabila (K1D024047)
4. Naufal Zaqie Al Faruq (K1D024050)

Disusun untuk memenuhi tugas *project*

Mata kuliah : *Machine Learning*

Dosen : Lutfiah Maharani S.Stat M.Stat

KEMENTERIAN PENDIDIKAN TINGGI, SAINS DAN TEKNOLOGI
UNIVERSITAS JENDERAL SOEDIRMAN
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
PROGRAM STUDI STATISTIKA
PURWOKERTO
2026

BAB I

PENDAHULUAN

1.1 Latar Belakang

Penyakit genetik merupakan salah satu masalah kesehatan yang disebabkan oleh perubahan atau mutasi pada gen maupun kromosom yang diwariskan dari orang tua kepada keturunannya. Penyakit genetik dapat menimbulkan berbagai gangguan kesehatan dengan tingkat keparahan yang berbeda-beda, sehingga deteksi dan identifikasi dini menjadi faktor penting dalam mendukung proses diagnosis serta penanganan yang tepat. Perkembangan teknologi kesehatan dan bioteknologi telah menghasilkan berbagai data medis yang mencakup karakteristik pasien, riwayat keluarga, hasil pemeriksaan laboratorium, serta biomarker genetik. Data tersebut memiliki potensi besar untuk dimanfaatkan dalam membantu proses identifikasi penyakit secara lebih cepat dan akurat. Namun, jumlah data yang besar dan kompleksitas hubungan antarvariabel sering kali menyulitkan proses analisis secara manual.

Machine Learning merupakan salah satu cabang kecerdasan buatan yang mampu mempelajari pola dari data dan menghasilkan prediksi berdasarkan pola tersebut. Salah satu metode yang banyak digunakan dalam bidang kesehatan adalah klasifikasi, yaitu proses pengelompokan suatu objek ke dalam kategori tertentu berdasarkan karakteristik yang dimiliki. Dalam konteks kesehatan, klasifikasi dapat digunakan untuk mengidentifikasi jenis penyakit berdasarkan data pasien dan hasil pemeriksaan medis. *Dataset* yang digunakan dalam penelitian ini berisi informasi mengenai karakteristik individu, riwayat keluarga, hasil pemeriksaan darah, biomarker genetik, serta indikator kesehatan lainnya yang berhubungan dengan penyakit genetik. Dengan memanfaatkan algoritma *machine learning*, diharapkan dapat dibangun model klasifikasi yang mampu memprediksi kategori penyakit genetik secara akurat berdasarkan data yang tersedia.

Penelitian ini dilakukan untuk menerapkan tahapan *machine learning* secara menyeluruh, mulai dari eksplorasi data, prapemrosesan, pemodelan, evaluasi, hingga interpretasi hasil. Selain memperoleh model dengan performa yang baik, penelitian ini

juga bertujuan untuk mengetahui faktor-faktor yang paling berpengaruh dalam proses klasifikasi penyakit genetik.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, penelitian ini dirumuskan ke dalam beberapa permasalahan yang akan dikaji. Rumusan masalah tersebut adalah sebagai berikut.

1. Bagaimana karakteristik data pasien yang digunakan dalam klasifikasi penyakit genetik?
2. Bagaimana melakukan proses analisis data agar dapat digunakan dalam pembangunan model *machine learning*?
3. Bagaimana membangun model *machine learning* untuk mengklasifikasikan jenis penyakit genetik berdasarkan data pasien?
4. Algoritma klasifikasi manakah yang menghasilkan performa terbaik dalam mengidentifikasi kategori penyakit genetik?
5. Faktor atau variabel apa yang paling berpengaruh terhadap hasil klasifikasi penyakit genetik?

1.3 Tujuan Penelitian

Tujuan penelitian disusun berdasarkan rumusan masalah yang telah ditetapkan. Adapun tujuan yang ingin dicapai dalam penelitian ini adalah sebagai berikut.

1. Menganalisis karakteristik *dataset* penyakit genetik melalui proses eksplorasi data.
2. Melakukan analisis data agar siap digunakan dalam proses pemodelan.
3. Membangun beberapa model *machine learning* untuk klasifikasi penyakit genetik.
4. Membandingkan performa berbagai algoritma klasifikasi menggunakan metrik evaluasi yang sesuai.
5. Mengidentifikasi variabel-variabel yang berpengaruh terhadap hasil klasifikasi penyakit genetik.

1.4 Manfaat Penelitian

Penelitian ini diharapkan dapat memberikan manfaat baik dari sisi akademis maupun praktis. Adapun manfaat yang diharapkan dari penelitian ini adalah sebagai berikut.

1. Menjadi sarana pembelajaran dalam penerapan metode klasifikasi pada data medis dan genetik.
2. Memberikan pengalaman dalam menerapkan seluruh tahapan *machine learning* workflow secara sistematis.
3. Membantu proses identifikasi penyakit genetik berdasarkan data pasien secara lebih cepat.
4. Memberikan informasi mengenai faktor-faktor yang berpengaruh terhadap klasifikasi penyakit genetik.
5. Menjadi referensi dalam pengembangan sistem pendukung keputusan di bidang kesehatan berbasis *machine learning*.

1.5 Batasan Masalah

Agar penelitian lebih terarah dan memiliki ruang lingkup yang jelas, diperlukan batasan masalah. Adapun batasan masalah dalam penelitian ini adalah sebagai berikut.

1. Penelitian menggunakan *dataset Genetic Disease Dataset* yang terdiri dari 1.000 observasi dan 13 variabel.
2. Variabel target yang digunakan adalah *Disease* yang merepresentasikan kategori penyakit genetik.
3. Penelitian berfokus pada permasalahan klasifikasi multikelas (*multiclass classification*).
4. Pemodelan dilakukan menggunakan beberapa algoritma klasifikasi *machine learning* sebagai pembandingan.
5. Evaluasi model dilakukan menggunakan metrik Accuracy, Precision, Recall, F1-Score, Confusion Matrix, dan ROC-AUC apabila relevan.
6. Hasil penelitian hanya berlaku pada *dataset* yang digunakan dan tidak dimaksudkan sebagai alat diagnosis medis secara langsung.

BAB II

TINJAUAN *DATASET*

2.1 Deskripsi *Dataset*

Dataset yang dighunakan dalam penelitian ini adalah *Genetic Disease Dataset*, yaitu *dataset* yang berisi informasi karakteristik individu, riwayat keluarga, hasil pemeriksaan laboratorium, biomarker genetik, serta indikator kesehatan lainnya yang berkaitan dengan berbagai jenis penyakit genetik. *Dataset* ini digunakan untuk membangun model *machine learning* yang mampu mengklasifikasikan jenis penyakit genetik berdasarkan karakteristik pasien.

Dataset terdiri atas 1.000 observasi dan 13 variabel, dengan satu variabel target berupa kategori penyakit genetik yang akan diprediksi. Permasalahan yang dibahas dalam penelitian ini termasuk ke dalam klasifikasi multikelas (*multiclass classification*) karena variabel target memiliki lebih dari dua kategori kelas. Data yang digunakan berasal dari sumber *dataset* publik (kaggle) yang dapat digunakan untuk keperluan penelitian dan pembelajaran *machine learning*.

2.2 Karakteristik *Dataset*

Berikut adalah Karakteristik *Dataset* yang digunakan dalam bentuk tabel.

Tabel 2.1 Karakteristik *Genetic Disease Dataset*

Karakteristik	Keterangan
Nama <i>Dataset</i>	<i>Genetic Disease Dataset</i>
Jumlah Observasi	1.000
Jumlah Variabel	13
Jumlah Fitur	12
Variabel Target	<i>Disease</i>
Jenis Masalah	Klasifikasi Multikelas

2.3 Deskripsi Variabel

Berikut adalah Deskripsi dari variabel yang digunakan dalam bentuk tabel.

Tabel 2.2 Deskripsi Variabel *Genetic Disease Dataset*

Variabel	Tipe Data	Deskripsi
<i>Age</i>	Numerik	Usia pasien (tahun)
<i>Gender</i>	Numerik(0/1)	Jenis kelamin pasien dengan 0 = Laki-laki dan 1 = Perempuan.
<i>Family_History</i>	Numerik(0/1)	Riwayat penyakit genetik dalam keluarga dengan 0 = Tidak dan 1 = Iya.
<i>Hemoglobin</i>	Numerik	Kadar Hemoglobin dalam darah
<i>Fetal_Hemoglobin</i>	Numerik	Persentase hemoglobin janin dalam darah
<i>RDW_CV</i>	Numerik	Ukuran tingkat variasi ukuran sel darah merah
<i>Serum_Ferritin</i>	Numerik	Kadar Ferritin serum yang menunjukkan cadangan zat besi tubuh
<i>BRCA1_Expression</i>	Numerik	Tingkat ekspresi gen BRCA1
<i>p53_Mutation</i>	Numerik(0/1)	Status mutasi gen p53 dengan 0 Normal dan 1 = Mutated.
<i>Sweat_Chloride</i>	Numerik	Kadar klorida dalam keringat
<i>Sickled_RBC_percent</i>	Numerik	Persentase sel darah merah berbentuk sabit
<i>IL6_Level</i>	Numerik	Kadar Interleukin-6 sebagai indikator

inflamasi

Disease

Numerik

Kategori penyakit genetik yang diprediksi

2.4 Variabel Target

Variabel target yang digunakan dalam penelitian ini adalah *Disease*. Variabel tersebut menunjukkan kategori penyakit genetik yang dimiliki oleh setiap individu berdasarkan hasil pemeriksaan laboratorium dan karakteristik medis yang tersedia dalam *dataset*. Karena variabel target memiliki beberapa kategori kelas, maka penelitian ini termasuk dalam permasalahan klasifikasi multikelas. Tujuan utama penelitian adalah membangun model *machine learning* yang mampu mengidentifikasi kategori penyakit genetik secara akurat berdasarkan variabel prediktor yang tersedia.

2.5 Variabel Prediktor

Penelitian ini menggunakan 12 variabel prediktor. Variabel prediktor terdiri atas karakteristik demografis, riwayat penyakit, hasil pemeriksaan laboratorium, serta biomarker genetik. Deskripsi lengkap setiap variabel disajikan pada Tabel 2.3.

1. *Age*
2. *Gender*
3. *Family_History*
4. *Hemoglobin*
5. *Fetal_Hemoglobin*
6. *RDW_CV*
7. *Serum_Ferritin*
8. *BRCA1_Expression*
9. *p53_Mutation*
10. *Sweat_Chloride*
11. *Sickled_RBC_Percent*
12. *IL6_Level*

BAB III

METODOLOGI

3.1 Metode Penelitian

Project ini menggunakan pendekatan *machine learning* dengan tujuan membangun model klasifikasi yang mampu memprediksi kategori penyakit genetik berdasarkan karakteristik pasien yang tersedia dalam *dataset*. Tahapan penelitian dilakukan secara sistematis mulai dari pengumpulan data, eksplorasi data, persiapan data, pembangunan model, evaluasi model, hingga interpretasi hasil. Pendekatan ini dipilih karena *machine learning* memiliki kemampuan untuk mengenali pola yang kompleks pada data dan menghasilkan prediksi yang akurat berdasarkan informasi yang tersedia.

Dataset yang digunakan adalah *Genetic Disease Dataset* yang diperoleh dari platform Kaggle. *Dataset* tersebut terdiri dari 1.000 observasi dan 13 variabel yang mencakup informasi usia, jenis kelamin, riwayat keluarga, hasil pemeriksaan laboratorium, biomarker genetik, serta kategori penyakit genetik yang menjadi variabel target. Permasalahan yang dibahas termasuk ke dalam klasifikasi multikelas (*multiclass classification*) karena variabel target memiliki 5 kategori penyakit.

Secara umum, alur penelitian yang dilakukan meliputi *Exploratory Data Analysis* (EDA), data *preprocessing*, pembagian data training dan testing, pembangunan model *machine learning*, evaluasi performa model, dan interpretasi hasil model.

3.2 Exploratory Data Analysis (EDA)

Exploratory Data Analysis (EDA) merupakan tahapan awal yang dilakukan untuk memahami karakteristik *dataset* sebelum memasuki tahap pemodelan. EDA bertujuan untuk memperoleh gambaran mengenai struktur data, kualitas data, pola distribusi variabel, hubungan antarvariabel, serta potensi permasalahan yang dapat memengaruhi hasil analisis.

Tahap EDA sangat penting dalam *machine learning* karena keputusan yang diambil pada tahap *preprocessing* dan pemodelan sangat bergantung pada hasil eksplorasi data. Dengan memahami karakteristik data secara menyeluruh, proses

pembangunan model dapat dilakukan dengan lebih tepat dan menghasilkan performa yang lebih baik.

3.2.1 Pemeriksaan Struktur *Dataset*

Tahap pertama dalam EDA adalah memeriksa struktur *dataset* yang digunakan. Pemeriksaan dilakukan untuk mengetahui jumlah observasi, jumlah variabel, tipe data masing-masing variabel, serta memastikan bahwa data telah terbaca dengan benar oleh perangkat lunak yang digunakan.

Selain itu, dilakukan analisis statistik deskriptif terhadap seluruh variabel numerik. Statistik yang diamati meliputi nilai minimum, maksimum, rata-rata (*mean*), median, kuartil, dan standar deviasi. Informasi tersebut memberikan gambaran awal mengenai karakteristik data, seperti rentang nilai, tingkat variasi data, dan kemungkinan adanya nilai ekstrem yang perlu diperhatikan pada tahap selanjutnya. Melalui analisis ini, peneliti dapat memahami kondisi umum *dataset* serta mengidentifikasi variabel yang memiliki karakteristik khusus yang mungkin memerlukan perlakuan tertentu dalam proses *preprocessing*.

3.2.2 Pemeriksaan *Missing Value*

Setelah memahami struktur data, langkah berikutnya adalah melakukan pemeriksaan terhadap *missing value* atau nilai yang hilang. *Missing value* dapat muncul karena berbagai faktor, seperti kesalahan pencatatan data, kegagalan alat ukur, maupun data yang tidak berhasil dikumpulkan pada saat proses pengambilan data. Keberadaan *missing value* dapat memengaruhi kualitas model *machine learning* karena sebagian besar algoritma tidak dapat memproses data yang tidak lengkap. Oleh karena itu, dilakukan identifikasi jumlah dan persentase *missing value* pada setiap variabel.

Hasil pemeriksaan ini digunakan untuk menentukan strategi penanganan yang sesuai, seperti menghapus data yang tidak lengkap atau melakukan imputasi menggunakan nilai statistik tertentu. Dengan demikian, data yang digunakan dalam proses pemodelan menjadi lebih konsisten dan representatif.

3.2.3 Pemeriksaan Data Duplikat

Selain *missing value*, dilakukan pula pemeriksaan terhadap kemungkinan adanya data duplikat. Data duplikat merupakan data yang tercatat lebih dari satu kali dengan informasi yang sama. Keberadaan data duplikat dapat menyebabkan distribusi data menjadi tidak proporsional dan berpotensi menimbulkan bias pada model. Pemeriksaan dilakukan dengan menghitung jumlah observasi yang memiliki nilai identik pada seluruh variabel. Apabila ditemukan data duplikat, maka data tersebut akan dihapus sehingga setiap observasi dalam *dataset* benar-benar merepresentasikan individu yang berbeda.

3.2.4 Analisis Distribusi Variabel Target

Variabel target dalam penelitian ini adalah *Disease*, yang menunjukkan kategori penyakit genetik yang dimiliki oleh setiap pasien. Analisis terhadap variabel target dilakukan untuk mengetahui jumlah observasi pada masing-masing kategori penyakit.

Distribusi variabel target sangat penting untuk diperhatikan karena dapat memengaruhi performa model klasifikasi. Jika terdapat perbedaan jumlah data yang sangat besar antar kategori penyakit, maka model berpotensi lebih sering memprediksi kelas yang dominan dibandingkan kelas lainnya. Analisis distribusi dilakukan menggunakan tabel frekuensi dan visualisasi diagram batang sehingga proporsi masing-masing kategori penyakit dapat diamati dengan lebih jelas. Hasil analisis ini menjadi dasar dalam menentukan strategi evaluasi model yang tepat.

3.2.5 Analisis Distribusi Variabel Prediktor

Analisis distribusi juga dilakukan terhadap seluruh variabel prediktor yang digunakan dalam penelitian. Variabel tersebut meliputi *Age*, *Hemoglobin*, *Fetal_Hemoglobin*, *RDW_CV*, *Serum_Ferritin*, *BRCA1_Expression*, *Sweat_Chloride*, *Sickled_RBC_Percent*, dan *IL6_Level*. Analisis dilakukan menggunakan histogram dan boxplot untuk melihat pola penyebaran data. Melalui histogram dapat diketahui bentuk distribusi data, apakah mendekati distribusi normal atau memiliki kemencengan tertentu. Sementara itu, boxplot digunakan untuk mendeteksi adanya outlier atau nilai pencilan yang berada jauh di luar rentang mayoritas data. Analisis distribusi variabel prediktor membantu peneliti memahami karakteristik masing-masing fitur sehingga

dapat menentukan metode *preprocessing* yang paling sesuai sebelum data digunakan dalam proses pelatihan model.

3.2.6 Analisis Hubungan Antar Variabel

Tahap selanjutnya adalah menganalisis hubungan antarvariabel menggunakan metrik korelasi. Analisis ini bertujuan untuk mengetahui sejauh mana keterkaitan antara satu variabel dengan variabel lainnya. Korelasi yang tinggi antar fitur dapat menunjukkan adanya informasi yang saling tumpang tindih. Sebaliknya, korelasi yang rendah menunjukkan bahwa masing-masing variabel memberikan informasi yang relatif berbeda terhadap model. Visualisasi korelasi dilakukan menggunakan *heatmap* sehingga pola hubungan antarvariabel dapat diamati dengan lebih mudah. Informasi ini juga dapat digunakan sebagai dasar dalam proses seleksi fitur dan interpretasi hasil model.

3.3 Data *Preprocessing*

Setelah proses eksplorasi data selesai dilakukan, tahap berikutnya adalah data *preprocessing*. Tahap ini bertujuan untuk menyiapkan data agar berada dalam kondisi yang optimal untuk digunakan oleh algoritma *machine learning*. Data yang belum diproses sering kali mengandung berbagai permasalahan seperti *missing value*, perbedaan skala antarvariabel, maupun format data yang tidak sesuai. Oleh karena itu, *preprocessing* dilakukan untuk meningkatkan kualitas data sehingga model dapat mempelajari pola yang terdapat dalam *dataset* dengan lebih efektif.

3.3.1 Penanganan *Missing Value*

Tahap pertama dalam *preprocessing* adalah membersihkan data dari berbagai permasalahan yang ditemukan pada tahap EDA. Jika terdapat *missing value*, maka dilakukan penanganan menggunakan metode yang sesuai dengan karakteristik data. Jika ditemukan data duplikat, maka data tersebut dihapus dari *dataset*. Proses pembersihan data bertujuan untuk memastikan bahwa seluruh observasi yang digunakan dalam penelitian memiliki kualitas yang baik dan dapat mewakili kondisi sebenarnya.

3.3.2 Pengecekan Data Duplikat

Pengecekan data duplikat dilakukan untuk memastikan bahwa setiap data dalam *dataset* bersifat unik dan tidak mengalami pengulangan. Keberadaan data duplikat dapat menyebabkan distribusi data menjadi tidak representatif sehingga berpotensi memengaruhi hasil analisis maupun performa model yang dibangun. Proses pengecekan dilakukan dengan membandingkan seluruh atribut pada setiap observasi untuk mengidentifikasi adanya data yang memiliki nilai identik. Apabila ditemukan data duplikat, maka data tersebut dihapus sehingga hanya satu data yang dipertahankan. Dengan demikian, *dataset* yang digunakan pada tahap selanjutnya telah terbebas dari pengulangan data.

3.3.3 Penanganan *Outlier*

Penanganan *outlier* dilakukan untuk mengurangi pengaruh nilai ekstrem yang dapat memengaruhi kualitas data dan performa model. *Outlier* merupakan data yang memiliki nilai jauh berbeda dibandingkan sebagian besar data lainnya sehingga berpotensi menyebabkan hasil pemodelan menjadi kurang optimal.

Pada penelitian ini, deteksi *outlier* dilakukan menggunakan metode *Interquartile Range* (IQR). Data yang berada di luar rentang batas yang ditentukan oleh metode IQR dikategorikan sebagai *outlier*. Selanjutnya, penanganan *outlier* dilakukan menggunakan metode *winsorization*, yaitu dengan mengganti nilai ekstrem menggunakan nilai batas bawah atau batas atas yang masih berada dalam rentang data normal. Metode ini dipilih karena dapat mengurangi pengaruh *outlier* tanpa mengurangi jumlah data yang digunakan dalam penelitian.

3.4 Data Construction

Tahap *data construction* merupakan proses penyusunan *dataset* yang telah melalui tahap pembersihan data agar siap digunakan dalam proses pemodelan. Pada tahap ini dilakukan pengorganisasian data sesuai dengan kebutuhan penelitian, meliputi penentuan variabel independen (*feature*) dan variabel dependen (*target*). Selain itu, dilakukan pembentukan *dataset* akhir yang akan digunakan pada proses pelatihan dan pengujian model. Tahap ini bertujuan untuk memastikan bahwa data telah memiliki struktur yang sesuai sehingga dapat digunakan secara optimal pada proses pemodelan dan evaluasi.

3.4.1 Pemisahan Variabel Prediktor dan Variabel Target

Setelah data dibersihkan, dilakukan pemisahan antara variabel prediktor dan variabel target. Variabel target yang digunakan adalah *Disease*, sedangkan seluruh variabel lainnya digunakan sebagai fitur yang akan menjadi dasar dalam proses prediksi. Pemisahan ini diperlukan karena algoritma *machine learning* membutuhkan data *input* berupa fitur dan data *output* berupa target untuk membangun pola klasifikasi.

3.4.2 Standardisasi Data

Karena variabel numerik dalam *dataset* memiliki rentang nilai yang berbeda-beda, dilakukan proses standardisasi menggunakan *StandardScaler*. Sebagai contoh, variabel *Age* memiliki satuan tahun, sedangkan variabel *Ferritin* dan *IL-6* memiliki satuan pengukuran yang berbeda. Perbedaan skala tersebut dapat menyebabkan beberapa algoritma *machine learning* memberikan bobot yang lebih besar pada variabel tertentu. Oleh karena itu, standardisasi dilakukan agar seluruh variabel berada pada skala yang relatif sama sehingga proses pembelajaran model menjadi lebih optimal.

3.4.3 Pembagian Data *Training* dan *Testing*

Tahap terakhir dalam *preprocessing* adalah membagi *dataset* menjadi data *training* dan data *testing* dengan proporsi 80:20. Sebanyak 80% data digunakan untuk melatih model, sedangkan 20% sisanya digunakan untuk menguji kemampuan model dalam melakukan prediksi pada data yang belum pernah dilihat sebelumnya. Pembagian data dilakukan secara acak menggunakan *random_state* tertentu agar hasil penelitian dapat direproduksi. Tahap ini penting untuk mengukur kemampuan generalisasi model dan menghindari penilaian performa yang terlalu optimistis.

3.5 Pemodelan *Machine Learning*

Tahap pemodelan merupakan inti dari penelitian ini, yaitu proses membangun model *machine learning* yang mampu mengklasifikasikan jenis penyakit genetik berdasarkan karakteristik pasien yang terdapat dalam *dataset*. Pada tahap ini, data *training* yang telah melalui proses *preprocessing* digunakan untuk melatih beberapa algoritma klasifikasi. Penggunaan lebih dari satu algoritma bertujuan untuk

membandingkan performa masing-masing model sehingga dapat diperoleh model yang paling baik dalam melakukan prediksi.

Karena variabel target *Disease* memiliki lebih dari dua kategori kelas, maka permasalahan yang diteliti termasuk ke dalam klasifikasi multikelas (*multiclass classification*). Setiap algoritma akan mempelajari pola hubungan antara variabel prediktor dan variabel target, kemudian menghasilkan model yang dapat digunakan untuk memprediksi kategori penyakit pada data baru.

3.5.1 Extreme Gradient Boosting (XG Boost)

Extreme Gradient Boosting (XG Boost) merupakan salah satu algoritma *ensemble learning* yang dikembangkan berdasarkan metode *Gradient Boosting*. Algoritma ini bekerja dengan membangun sejumlah pohon keputusan (*decision tree*) secara bertahap, di mana setiap pohon baru dibangun untuk memperbaiki kesalahan prediksi yang dihasilkan oleh pohon sebelumnya. Proses pembelajaran dilakukan secara berurutan sehingga model mampu meningkatkan akurasi prediksi dari waktu ke waktu.

XG Boost dikenal sebagai salah satu algoritma *machine learning* yang memiliki performa tinggi dalam berbagai kompetisi data science karena mampu menangani hubungan yang kompleks antarvariabel serta memiliki kemampuan generalisasi yang baik. Selain itu, algoritma ini dilengkapi dengan mekanisme regularisasi yang dapat membantu mengurangi risiko *overfitting* sehingga model yang dihasilkan lebih stabil ketika digunakan pada data baru.

3.5.2 Random Forest

Random Forest merupakan pengembangan dari Decision Tree yang termasuk ke dalam metode *ensemble learning*. Algoritma ini bekerja dengan membangun sejumlah pohon keputusan secara acak, kemudian menggabungkan hasil prediksi dari seluruh pohon untuk menentukan prediksi akhir.

Penggunaan banyak pohon keputusan membuat Random Forest lebih stabil dan lebih tahan terhadap *overfitting* dibandingkan Decision Tree tunggal. Selain itu, Random Forest mampu menangani hubungan yang kompleks antarvariabel dan sering menghasilkan performa yang baik pada berbagai kasus klasifikasi. Keunggulan lain

dari Random Forest adalah kemampuannya dalam menghitung tingkat kepentingan variabel (*feature importance*). Informasi ini dapat digunakan untuk mengidentifikasi faktor-faktor yang paling berpengaruh dalam proses klasifikasi penyakit genetik.

3.5.3 Support Vector Machine (SVM)

Support Vector Machine (SVM) merupakan algoritma klasifikasi yang bekerja dengan mencari batas pemisah (*hyperplane*) terbaik yang mampu memisahkan kelas-kelas yang berbeda secara optimal. Algoritma ini berusaha memaksimalkan jarak antara *hyperplane* dengan titik data terdekat dari masing-masing kelas yang disebut sebagai *support vector*. SVM dikenal memiliki kemampuan generalisasi yang baik dan mampu menghasilkan performa yang tinggi pada berbagai permasalahan klasifikasi. Selain itu, penggunaan fungsi kernel memungkinkan SVM menangani hubungan nonlinier yang kompleks antarvariabel.

Pada penelitian ini, SVM digunakan sebagai salah satu algoritma pembanding untuk melihat kemampuannya dalam mengklasifikasikan penyakit genetik berdasarkan data pasien yang tersedia.

3.6 Hyperparameter Tuning

Setiap algoritma *machine learning* memiliki parameter tertentu yang dapat diatur untuk meningkatkan performa model. Parameter tersebut dikenal sebagai *hyperparameter*. Nilai *hyperparameter* yang kurang tepat dapat menyebabkan model memiliki performa yang kurang optimal, baik karena terlalu sederhana (*underfitting*) maupun terlalu kompleks (*overfitting*).

Oleh karena itu, dilakukan proses *hyperparameter tuning* untuk memperoleh kombinasi parameter terbaik pada masing-masing algoritma. Proses *tuning* dilakukan menggunakan teknik pencarian parameter seperti Grid Search Cross Validation atau metode serupa yang tersedia pada perangkat lunak yang digunakan.

Beberapa *hyperparameter* yang disesuaikan dalam penelitian ini antara lain:

- Jumlah pohon, kedalaman pohon, (*n_estimators*, *max_depth*) pada Random Forest dan XG Boost.
- Jumlah maksimal fitur, jumlah minimum sampel (*max_features*, *min_samples_split*, *min_samples_leaf*) pada Random Forest.

- Kontribusi pohon, persentase baris dan persentase kolom data (*learning_rate*, *subsample*, *colsample_bytree*) pada XG Boost.
- Nilai parameter C, gamma dan jenis kernel pada SVM.

Pemilihan *hyperparameter* terbaik dilakukan berdasarkan nilai evaluasi yang diperoleh selama proses validasi silang (*cross validation*).

3.7 Evaluasi Model

Setelah proses pelatihan selesai dilakukan, setiap model dievaluasi menggunakan data testing yang sebelumnya tidak digunakan selama proses pembelajaran. Evaluasi bertujuan untuk mengetahui kemampuan model dalam melakukan prediksi terhadap data baru serta membandingkan performa antaralgoritma yang digunakan. Pada penelitian ini digunakan beberapa metrik evaluasi yang umum digunakan pada permasalahan klasifikasi multikelas.

3.7.1 Accuracy

Accuracy digunakan untuk mengukur proporsi jumlah prediksi yang benar dibandingkan dengan seluruh data yang dievaluasi. Nilai accuracy yang tinggi menunjukkan bahwa model mampu melakukan klasifikasi dengan tingkat ketepatan yang baik. Meskipun demikian, accuracy tidak selalu cukup untuk menggambarkan performa model secara menyeluruh, terutama apabila terdapat ketidakseimbangan jumlah data pada setiap kelas.

3.7.2 Precision

Precision digunakan untuk mengukur tingkat ketepatan model dalam memberikan prediksi pada suatu kelas tertentu. Nilai precision yang tinggi menunjukkan bahwa sebagian besar prediksi yang diberikan model memang benar termasuk ke dalam kelas tersebut. Dalam konteks klasifikasi penyakit, precision penting untuk mengurangi kemungkinan kesalahan identifikasi penyakit yang sebenarnya tidak dimiliki oleh pasien.

3.7.3 Recall

Recall digunakan untuk mengukur kemampuan model dalam menemukan seluruh data yang benar-benar termasuk ke dalam suatu kelas tertentu. Nilai recall yang

tinggi menunjukkan bahwa model mampu mengenali sebagian besar kasus yang memang termasuk dalam kategori penyakit tersebut. Pada bidang kesehatan, recall menjadi salah satu metrik yang penting karena berkaitan dengan kemampuan model mendeteksi pasien yang benar-benar mengalami suatu kondisi penyakit.

3.7.4 F1-Score

F1-Score merupakan rata-rata harmonik antara precision dan recall. Metrik ini digunakan untuk memberikan penilaian yang lebih seimbang terhadap performa model, terutama ketika terdapat perbedaan distribusi jumlah data antar kelas. Semakin tinggi nilai F1-Score, semakin baik keseimbangan antara kemampuan model dalam memberikan prediksi yang tepat dan kemampuannya dalam mendeteksi seluruh kasus yang relevan.

3.7.5 Confusion Matrix

Confusion Matrix digunakan untuk menampilkan perbandingan antara kelas aktual dan kelas hasil prediksi model. Melalui confusion matrix dapat diketahui jumlah prediksi yang benar maupun kesalahan klasifikasi yang terjadi pada setiap kategori penyakit. Visualisasi ini membantu peneliti memahami pola kesalahan yang dilakukan model dan mengidentifikasi kelas penyakit yang paling sulit dibedakan.

3.7.6 ROC-AUC

Apabila memungkinkan, evaluasi juga dilakukan menggunakan metrik ROC-AUC dengan pendekatan *One-vs-Rest (OvR)* untuk kasus multikelas. ROC-AUC digunakan untuk mengukur kemampuan model dalam membedakan antar kelas penyakit. Nilai ROC-AUC berkisar antara 0 hingga 1. Semakin mendekati 1, semakin baik kemampuan model dalam melakukan klasifikasi.

3.8 Interpretasi Hasil Model

Tahap terakhir dalam penelitian adalah interpretasi hasil model yang telah dibangun. Interpretasi dilakukan untuk memahami performa model terbaik serta mengetahui variabel-variabel yang memberikan kontribusi terbesar terhadap proses klasifikasi penyakit genetik. Perbandingan performa seluruh algoritma dilakukan

berdasarkan nilai Accuracy, Precision, Recall, F1-Score, serta hasil Confusion Matrix. Model dengan performa terbaik dipilih sebagai model utama dalam penelitian ini.

Selain itu, dilakukan analisis terhadap tingkat kepentingan variabel (*feature importance*), khususnya pada algoritma yang mendukung interpretasi fitur seperti Random Forest dan Decision Tree. Analisis ini bertujuan untuk mengidentifikasi faktor-faktor yang paling berpengaruh dalam membedakan kategori penyakit genetik.

Hasil interpretasi diharapkan dapat memberikan pemahaman yang lebih mendalam mengenai hubungan antara karakteristik pasien, biomarker genetik, hasil pemeriksaan laboratorium, dan jenis penyakit genetik yang diprediksi oleh model. Informasi tersebut dapat menjadi dasar bagi penelitian lanjutan maupun pengembangan sistem pendukung keputusan berbasis *machine learning* di bidang kesehatan.

BAB IV

HASIL DAN PEMBAHASAN

4.1 *Business Understanding*

Penyakit genetik merupakan kelompok penyakit yang disebabkan oleh kelainan atau mutasi pada gen maupun kromosom yang dapat diturunkan dalam keluarga. Identifikasi penyakit genetik sejak dini sangat penting karena dapat membantu tenaga medis dalam menentukan tindakan diagnosis lanjutan, memberikan penanganan yang lebih tepat, serta meningkatkan kualitas hidup pasien. Namun, proses identifikasi sering kali memerlukan analisis terhadap berbagai informasi klinis dan hasil pemeriksaan laboratorium sehingga membutuhkan waktu dan keahlian khusus.

Perkembangan *machine learning* membuka peluang untuk membantu proses identifikasi penyakit genetik melalui pemanfaatan data pasien. Dengan memanfaatkan karakteristik pasien, seperti usia, jenis kelamin, riwayat penyakit dalam keluarga, hasil pemeriksaan laboratorium, dan biomarker genetik, model klasifikasi dapat mempelajari pola yang membedakan setiap kategori penyakit. Model yang dihasilkan diharapkan mampu memberikan prediksi secara cepat dan konsisten sehingga dapat menjadi pendukung dalam proses pengambilan keputusan.

Berdasarkan permasalahan tersebut, penelitian ini bertujuan membangun model klasifikasi menggunakan beberapa algoritma *machine learning*, yaitu Random Forest, Support Vector Machine (SVM), dan XG Boost, untuk mengklasifikasikan kategori penyakit genetik berdasarkan data pasien. Selain membandingkan performa masing-masing algoritma, penelitian ini juga bertujuan mengidentifikasi variabel yang paling berpengaruh terhadap hasil klasifikasi melalui analisis *feature importance*. Model terbaik dipilih berdasarkan hasil evaluasi menggunakan metrik Accuracy, Precision, dan ROC-AUC.

4.2 *Data Understanding*

Tahap *Data Understanding* bertujuan untuk memperoleh pemahaman terhadap karakteristik *dataset* yang akan digunakan dalam proses pemodelan. Pada tahap ini dilakukan identifikasi struktur data, jenis variabel, statistik deskriptif, distribusi kelas, serta analisis eksploratif melalui visualisasi data. Pemahaman terhadap karakteristik

dataset diperlukan agar proses *preprocessing* dan pemodelan dapat dilakukan dengan tepat.

4.2.1 Struktur *Dataset*

Dataset yang digunakan dalam penelitian ini adalah *Genetic Disease Dataset* yang terdiri atas 1.000 observasi dengan 13 variabel, yaitu 12 variabel prediktor dan satu variabel target (*Disease*). Variabel prediktor yang digunakan meliputi *Age*, *Gender*, *Family_History*, *Hemoglobin*, *Fetal_Hemoglobin*, *RDW_CV*, *Serum_Ferritin*, *BRCA1_Expression*, *p53_Mutation*, *Sweat_Chloride*, *Sickled_RBC_Percent*, dan *IL6_Level*.

Tabel 4.1 Struktur Variabel Penelitian

Variabel	Tipe Data
<i>Age</i>	Int64
<i>Gender</i>	Int64
<i>Famili_History</i>	Int64
<i>Hemoglobin</i>	Float64
<i>Fetal_Hemoglobin</i>	Float64
<i>RDW_CV</i>	Float64
<i>Serum_Ferritin</i>	Float64
<i>BRCA1_Expression</i>	Float64
<i>p53_Mutation</i>	Int64
<i>Sweat_Chloride</i>	Float64
<i>Sickled_RBC_Percent</i>	Float64
<i>IL6_Level</i>	Float64
<i>Disease</i>	Int64

Berdasarkan Tabel 4.1, seluruh variabel pada *dataset* direpresentasikan menggunakan tipe data numerik. Meskipun demikian, tidak semua variabel bersifat kontinu. Variabel *Gender*, *Family_History*, *p53_Mutation*, dan *Disease* merupakan variabel kategorik biner yang telah dikodekan dalam bentuk numerik sehingga dapat diproses oleh algoritma *machine learning*. Sementara itu, variabel *Age*, *Hemoglobin*,

Fetal_Hemoglobin, *RDW_CV*, *Serum_Ferritin*, *BRCA1_Expression*, *Sweat_Chloride*, *Sickled_RBC_Percent*, dan *IL6_Level* merupakan variabel numerik yang merepresentasikan hasil pengukuran karakteristik pasien maupun biomarker laboratorium. Kondisi data yang sudah sepenuhnya berbentuk angka ini mengindikasikan bahwa fitur kategorikal kemungkinan besar telah melalui proses encoding awal, sehingga *dataset* ini sudah sangat siap untuk langsung diproses tanpa memerlukan penanganan data teks atau imputasi tambahan.

4.2.2 Statistika Deskriptif

Statistik deskriptif dilakukan untuk memberikan gambaran umum mengenai karakteristik variabel numerik yang digunakan dalam penelitian. Analisis ini meliputi ukuran pemusatan data, ukuran penyebaran data, serta rentang nilai masing-masing variabel. Hasil statistik deskriptif variabel numerik disajikan pada Tabel 4.2.

Tabel 4.2 Statistika Deskriptif Variabel

Variabel	Count	Mean	Std	Min	Q1	Med	Q3	Max
<i>Age</i>	1.000	40,08	17,39	10	25	41	56	69
<i>Hemoglobin</i>	1.000	10,48	2,96	4,2	7,8	10,41	13,13	17,03
<i>Fetal_Hemoglobin</i>	1.000	7,95	7,7	-1,43	1,1	4,51	15,12	28,75
<i>RDW_CV</i>	1.000	15,27	2,49	9,48	13,39	14,55	17,11	23,83
<i>Serum_Ferritin</i>	1.000	99,65	37,22	6,93	70,51	105,39	128,12	193,74
<i>BRCA1_Expression</i>	1.000	0,31	0,25	-0,11	0,15	0,24	0,35	1,15
<i>Sweat_Chloride</i>	1.000	46,54	13,81	18,16	36,91	42,5	51,64	88,80
<i>Sickled_RBC_Percent</i>	1.000	6,71	11,83	-1,66	0,58	1,22	2,2	48,90
<i>IL6_Level</i>	1.000	10,52	7,63	-0,59	4,68	6,65	17,29	34,12

Berdasarkan Tabel 4.2, seluruh variabel numerik memiliki jumlah pengamatan sebanyak 1.000 observasi, yang menunjukkan bahwa setiap variabel memiliki data yang lengkap. Nilai rata-rata (*mean*) dan simpangan baku (*standard deviation*) pada masing-masing variabel menunjukkan adanya variasi karakteristik antarvariabel. Sebagai contoh, variabel *Age* memiliki rata-rata sebesar 40,08 tahun dengan rentang

nilai antara 10 hingga 69 tahun, sedangkan variabel *Serum_Ferritin* memiliki rata-rata sebesar 99,65 dengan rentang nilai 6,93–193,74.

Selain itu, beberapa variabel seperti *Fetal_Hemoglobin*, *BRCA1_Expression*, *Sickled_RBC_Percent*, dan *IL6_Level* memiliki nilai minimum di bawah nol. Nilai tersebut masih dapat diterima karena merupakan hasil simulasi atau transformasi data pada *dataset* dan tidak menunjukkan adanya kesalahan pencatatan. Perbedaan rentang nilai antarvariabel juga mengindikasikan bahwa data memiliki skala yang beragam sehingga proses standardisasi diperlukan sebelum dilakukan pemodelan, terutama pada algoritma yang sensitif terhadap skala data.

4.2.3 Keseimbangan Data

Sebelum proses pemodelan dilakukan, perlu dilakukan pemeriksaan terhadap distribusi kelas pada variabel target (*Disease*). Tahap ini bertujuan untuk mengetahui apakah *dataset* memiliki distribusi kelas yang seimbang (*balanced*) atau mengalami ketidakseimbangan kelas (*class imbalance*). Distribusi kelas yang tidak seimbang dapat menyebabkan model cenderung memprediksi kelas mayoritas sehingga menurunkan kemampuan model dalam mengenali kelas minoritas. Oleh karena itu, analisis keseimbangan data menjadi salah satu tahapan penting sebelum proses pemodelan dilakukan.

Distribusi jumlah observasi pada masing-masing kategori penyakit genetik disajikan pada Tabel 4.3.

Tabel 4.3 Distribusi Jumlah Observasi


<i>Disease</i>	Jumlah
0	205
1	204
2	199
3	196
4	196

Berdasarkan Tabel 4.3, jumlah observasi pada setiap kategori penyakit genetik relatif seimbang. Tidak terdapat perbedaan jumlah data yang signifikan antar kelas

sehingga *dataset* tidak mengalami permasalahan *class imbalance*. Kondisi ini menunjukkan bahwa setiap kategori penyakit memiliki representasi yang cukup dalam proses pelatihan model. Dengan demikian, penelitian ini tidak memerlukan teknik penyeimbangan data, seperti *oversampling*, *undersampling*, maupun *Synthetic Minority Over-sampling Technique* (SMOTE), sebelum dilakukan proses pemodelan.

4.2.4 Visualisasi Data


Visualisasi data dilakukan sebagai bagian dari *exploratory data analysis* (EDA) untuk memperoleh pemahaman yang lebih mendalam mengenai karakteristik *dataset* sebelum dilakukan tahap *data preparation*. Melalui visualisasi, pola distribusi data, keberadaan pencilan (*outlier*), serta hubungan antarvariabel dapat diamati secara lebih mudah. Pada penelitian ini, visualisasi dilakukan menggunakan histogram, *boxplot*, dan *heatmap* korelasi.



Gambar 4.1 Histogram Variabel Numerik


Histogram digunakan untuk menggambarkan distribusi masing-masing variabel numerik. Berdasarkan Gambar 4.1, setiap variabel menunjukkan pola distribusi yang berbeda-beda. Variabel seperti *Age* memiliki distribusi yang relatif

merata karena data usia tersebar pada rentang 10 hingga 69 tahun. Sementara itu, beberapa variabel laboratorium, seperti *Serum_Ferritin*, *Sickled_RBC_Percent*, dan *IL6_Level*, menunjukkan distribusi yang cenderung menceng (*skewed*), sehingga sebagian besar observasi terkonsentrasi pada rentang nilai tertentu dengan beberapa nilai yang berada pada rentang yang lebih tinggi. Perbedaan pola distribusi ini menunjukkan bahwa karakteristik setiap variabel tidak seragam, yang merupakan kondisi umum pada data medis dan biologis.




Gambar 4.2 *Boxplot* Variabel Numerik

Visualisasi menggunakan *boxplot* bertujuan untuk mengidentifikasi keberadaan pencilan (*outlier*) pada setiap variabel numerik. Berdasarkan Gambar 4.3, beberapa variabel memiliki nilai yang berada di luar rentang kuartil, terutama pada *BRCA1_Expression*, *Sweat_Chloride*, *Sickled_RBC_Percent*, dan *RDW_CV*. Keberadaan pencilan tersebut tidak serta-merta menunjukkan kesalahan data, melainkan dapat merepresentasikan variasi kondisi klinis pasien. Oleh karena itu, pada penelitian ini pencilan tidak dihapus dan tetap dipertahankan agar informasi yang terkandung dalam data tetap terjaga selama proses pemodelan.




Gambar 4.3 Distribusi Variabel Kategorik Biner

Distribusi variabel kategorik ditampilkan pada Gambar 4.3. Variabel target (*Disease*) memiliki proporsi yang hampir sama pada setiap kategori, masing-masing sekitar 20%, sehingga *dataset* tidak mengalami permasalahan *class imbalance*. Kondisi ini menguntungkan karena setiap kelas memiliki representasi yang relatif setara selama proses pelatihan model. Sementara itu, variabel *Gender* juga menunjukkan distribusi yang hampir seimbang antara kategori laki-laki dan perempuan. Berbeda dengan kedua variabel tersebut, variabel *Family_History* didominasi oleh kategori tanpa riwayat keluarga (59,6%), sedangkan kategori dengan riwayat keluarga mencapai 40,4%. Adapun variabel *p53_Mutation* memiliki distribusi yang lebih tidak seimbang, di mana sekitar 85,3% observasi tidak mengalami mutasi dan hanya 14,7% yang memiliki mutasi. Meskipun demikian, distribusi tersebut masih mencerminkan kondisi yang wajar pada data medis sehingga tidak dilakukan perlakuan khusus terhadap variabel tersebut.



Gambar 4.4 *Heatmap* Korelasi Antarvariabel

Hubungan linear antarvariabel numerik dianalisis menggunakan *heatmap* korelasi pada Gambar 4.4. Hasil visualisasi menunjukkan adanya beberapa pasangan variabel yang memiliki korelasi cukup kuat, baik positif maupun negatif. Korelasi positif yang cukup tinggi terlihat antara *Fetal_Hemoglobin* dan *RDW_CV* (0,76), serta antara *Hemoglobin* dan *IL6_Level* (0,75). Sebaliknya, korelasi negatif yang kuat ditemukan antara *Hemoglobin* dan *Fetal_Hemoglobin* (-0,84), serta antara *Hemoglobin* dan *RDW_CV* (-0,71). Meskipun terdapat beberapa hubungan yang cukup kuat, tidak ditemukan pasangan variabel dengan nilai korelasi yang mendekati ± 1 . Hal ini menunjukkan bahwa setiap variabel masih memberikan informasi yang berbeda sehingga seluruh variabel tetap dipertahankan sebagai prediktor dalam proses pemodelan.



Gambar 4.5 Korelasi Variabel terhadap Target

Hubungan antara masing-masing variabel dengan variabel target (*Disease*) ditunjukkan pada Gambar 4.5. Berdasarkan hasil korelasi, variabel *Sweat_Chloride* memiliki hubungan positif terbesar terhadap target dengan koefisien sebesar 0,56, diikuti oleh *Serum_Ferritin* (0,51) dan *IL6_Level* (0,45). Variabel *Sickled_RBC_Percent* dan *Hemoglobin* juga menunjukkan hubungan positif dengan koefisien masing-masing sebesar 0,33 dan 0,32. Sebaliknya, variabel *Fetal_Hemoglobin* (-0,27), *RDW_CV* (-0,19), dan *Age* (-0,08) memiliki korelasi negatif terhadap target. Sementara itu, variabel *Gender*, *Family_History*, *BRCA1_Expression*, dan *p53_Mutation* menunjukkan nilai korelasi yang sangat kecil atau mendekati nol, sehingga hubungan linear langsung terhadap variabel target relatif lemah. Meskipun demikian, variabel-variabel tersebut tetap dipertahankan karena algoritma klasifikasi *machine learning* tidak hanya memanfaatkan hubungan linear, tetapi juga mampu mempelajari pola interaksi yang lebih kompleks antarvariabel.

4.3 Data Preprocessing

Tahap *data preprocessing* dilakukan untuk memastikan kualitas data sebelum digunakan pada proses pemodelan. Pada tahap ini dilakukan pemeriksaan terhadap kelengkapan data, keberadaan data duplikat, serta penanganan *outlier* yang berpotensi memengaruhi hasil pembentukan model. Proses ini bertujuan menghasilkan *dataset* yang lebih bersih dan representatif sehingga mampu meningkatkan kualitas model klasifikasi yang dibangun.

4.3.1 Pemeriksaan *Missing Value* dan Data Duplikat

Sebelum dilakukan proses pemodelan, *dataset* terlebih dahulu diperiksa untuk mengidentifikasi keberadaan *missing value* dan data duplikat. Pemeriksaan *missing value* bertujuan memastikan bahwa setiap variabel memiliki informasi yang lengkap, sedangkan pemeriksaan data duplikat dilakukan untuk menghindari adanya observasi yang tercatat lebih dari satu kali sehingga dapat menyebabkan bias pada proses pelatihan model.

```
Missing values in each column:
Age                0
Gender             0
Family_History     0
Hemoglobin         0
Fetal_Hemoglobin   0
RDW_CV            0
Serum_Ferritin     0
BRCA1_Expression   0
p53_Mutation       0
Sweat_Chloride     0
Sickled_RBC_Percent 0
IL6_Level          0
Disease            0
dtype: int64


Number of duplicate rows:
0
```

Gambar 4.6 Hasil Pemeriksaan *Missing Value* dan Data Duplikat

Berdasarkan hasil pemeriksaan, seluruh variabel memiliki jumlah *missing value* sebanyak nol sehingga tidak diperlukan proses imputasi data. Selain itu, tidak ditemukan observasi yang terduplikasi pada *dataset*. Dengan demikian, seluruh data dapat langsung digunakan pada tahapan berikutnya tanpa memerlukan proses pembersihan tambahan.

4.3.2 Penanganan *Outlier*

Berdasarkan hasil EDA terutama pada Gambar 4.2, beberapa variabel numerik teridentifikasi memiliki nilai pencilan (*outlier*). Keberadaan *outlier* dapat memengaruhi proses pembelajaran model, terutama pada algoritma yang sensitif terhadap nilai ekstrem. Oleh karena itu, dilakukan penanganan *outlier* untuk menghasilkan distribusi data yang lebih representatif sebelum memasuki tahap konstruksi data.



Gambar 4.7 Hasil Penanganan *Outlier*

Berdasarkan Gambar 4.7, penanganan *outlier* dilakukan dengan membatasi nilai yang berada di luar rentang IQR. Nilai yang berada di bawah batas bawah (*lower bound*) diubah menjadi nilai batas bawah, sedangkan nilai yang melebihi batas atas (*upper bound*) diubah menjadi nilai batas atas. Dengan pendekatan ini, seluruh observasi tetap dipertahankan sehingga tidak terjadi pengurangan jumlah data. Setelah proses *capping*, jumlah *outlier* pada setiap variabel berkurang dan distribusi data menjadi lebih terkendali tanpa menghilangkan informasi yang terkandung dalam *dataset*.

4.4 Data Construction

Setelah melalui tahap *data preparation*, *dataset* selanjutnya dipersiapkan untuk proses pemodelan melalui tahap *data construction*. Tahap ini meliputi standardisasi data, *feature selection*, dan pembagian data menjadi data pelatihan (*training data*) serta data pengujian (*testing data*).

Tabel 4.1 Hasil Standardisasi Lima Observasi Pertama

Variabel	Data ke- 1	Data ke- 2	Data ke- 3	Data ke- 4	Data ke- 5
<i>Age</i>	0.4560	0.7436	0.4560	-0.7522	-0.1194
<i>Gender</i>	1	0	1	1	0
<i>Family_History</i>	1	0	1	0	0
<i>Hemoglobin</i>	-1.0280	-1.0584	-0.7544	-0.6530	-0.5720
<i>Fetal_Hemoglobin</i>	0.6737	0.9724	-0.1030	0.9594	1.0400
<i>RDW_CV</i>	-0.6449	1.2026	1.0574	1.4809	1.8400
<i>Serum_Ferritin</i>	-1.2371	-1.7987	-1.8703	-1.9436	-1.4025
<i>BRCA1_Expression</i>	0.3578	0.3075	-0.4469	-0.0446	0.0057
<i>p53_Mutation</i>	0	0	0	0	0
<i>Sweat_Chloride</i>	-0.0691	-0.5948	-1.0351	0.9309	-0.1168
<i>Sickled_RBC_percent</i>	-0.6759	-0.4105	-0.0339	-0.3117	-0.0956
<i>IL6_Level</i>	-0.5803	-1.0970	-1.0432	-0.2931	-0.6774
<i>Disease</i>	0	3	0	0	0

Berdasarkan hasil standardisasi, seluruh variabel numerik telah berada pada skala yang seragam sehingga perbedaan rentang nilai antarvariabel menjadi lebih kecil. Variabel biner seperti *Gender*, *Family_History*, dan *p53_Mutation* tidak mengalami perubahan karena telah berada pada skala yang sesuai.


Selanjutnya, variabel *Disease* ditetapkan sebagai variabel target, sedangkan seluruh variabel lainnya digunakan sebagai variabel prediktor dalam proses pembangunan model klasifikasi. *Dataset* kemudian dibagi menjadi data pelatihan (*training data*) dan data pengujian (*testing data*) dengan proporsi 80:20.

Ukuran X_train : (800, 12)
Ukuran X_test : (200, 12)
Ukuran y_train : (800,)
Ukuran y_test : (200,)

Gambar 4.8 Pembagian Data

Hasil pembagian menunjukkan bahwa sebanyak 800 observasi digunakan sebagai data pelatihan dan 200 observasi digunakan sebagai data pengujian. *Dataset* hasil *data construction* selanjutnya digunakan pada tahap pembangunan model klasifikasi.

Sebelum proses pembangunan model dilakukan, analisis *feature importance* digunakan untuk mengetahui tingkat kontribusi masing-masing variabel prediktor terhadap variabel target (*Disease*). Hasil analisis *feature importance* disajikan pada Gambar 4.9.




Gambar 4.9 Hasil *Feature Importance* Variabel Prediktor terhadap *Disease*

Berdasarkan Gambar 4.9, variabel *Sickled_RBC_Percent* memiliki nilai *feature importance* tertinggi, yaitu sebesar 0,1737, sehingga menjadi variabel yang


memberikan kontribusi paling besar dalam proses klasifikasi penyakit genetik. Variabel lain yang juga memiliki kontribusi tinggi adalah *Fetal_Hemoglobin* (0,1373), *Sweat_Chloride* (0,1352), *BRCA1_Expression* (0,1301), *IL6_Level* (0,1262), dan *Serum_Ferritin* (0,1190). Sementara itu, *Hemoglobin* (0,0761) dan *RDW_CV* (0,0562) menunjukkan tingkat kepentingan yang sedang terhadap proses klasifikasi.

Di sisi lain, variabel *p53_Mutation* (0,0293), *Age* (0,0116), *Gender* (0,0027), dan *Family_History* (0,0025) memiliki nilai *feature importance* yang relatif rendah. Hal tersebut menunjukkan bahwa variabel-variabel tersebut memberikan kontribusi yang lebih kecil dibandingkan variabel lainnya dalam membedakan kategori penyakit genetik pada *dataset* yang digunakan.

Selanjutnya, interpretasi model dilakukan menggunakan SHAP (*SHapley Additive exPlanations*) untuk mengetahui kontribusi setiap variabel terhadap prediksi model pada masing-masing kelas penyakit genetik. Berbeda dengan *feature importance* yang hanya menunjukkan tingkat kepentingan suatu variabel secara keseluruhan, SHAP memberikan informasi mengenai besarnya pengaruh setiap variabel terhadap prediksi pada setiap kelas.



Gambar 4.10 Hasil Analisis SHAP



Gambar 4.11 Hasil SHAP *Local Explanation* pada Salah Satu Observasi

Berdasarkan Gambar 4.10, *Sickled_RBC_Percent* memiliki nilai SHAP rata-rata tertinggi sehingga menjadi variabel yang memberikan pengaruh paling besar terhadap hasil prediksi model. Variabel lain yang juga menunjukkan kontribusi tinggi adalah *IL6_Level*, *BRCA1_Expression*, *Fetal_Hemoglobin*, *Sweat_Chloride*, dan *Serum_Ferritin*. Hasil tersebut sejalan dengan analisis *feature importance* sebelumnya, yang menunjukkan bahwa variabel-variabel tersebut merupakan faktor utama yang digunakan model dalam membedakan kategori penyakit genetik. Sebaliknya, *Age*, *Gender*, dan *Family_History* memiliki nilai SHAP yang relatif kecil sehingga kontribusinya terhadap prediksi model lebih rendah dibandingkan variabel lainnya.

Untuk memperoleh gambaran yang lebih rinci mengenai proses pengambilan keputusan model, dilakukan analisis SHAP pada salah satu observasi data uji. Berdasarkan Gambar 4.11, terlihat bahwa *Sickled_RBC_Percent* memberikan kontribusi positif terhadap hasil prediksi, sedangkan variabel *Fetal_Hemoglobin*, *Hemoglobin*, *Serum_Ferritin*, *BRCA1_Expression*, *IL6_Level*, dan *RDW_CV* memberikan kontribusi ke arah yang berlawanan sehingga memengaruhi nilai prediksi akhir. Visualisasi ini menunjukkan bahwa keputusan model tidak ditentukan oleh satu variabel saja, melainkan merupakan hasil kombinasi kontribusi dari seluruh variabel prediktor dalam menghasilkan prediksi pada suatu observasi.

Berdasarkan hasil analisis *feature importance* dan SHAP, terlihat bahwa setiap variabel memiliki tingkat kontribusi yang berbeda terhadap proses klasifikasi penyakit genetik. Meskipun demikian, seluruh variabel prediktor tetap digunakan dalam proses pembangunan model. Keputusan ini diambil karena variabel dengan nilai kontribusi yang rendah masih dapat memberikan informasi yang saling melengkapi ketika dikombinasikan dengan variabel lain. Selain itu, algoritma berbasis *ensemble* yang

digunakan dalam penelitian ini mampu memanfaatkan interaksi antarvariabel sehingga seluruh fitur tetap berpotensi meningkatkan performa model secara keseluruhan.


4.5 Pemodelan dan Evaluasi

Setelah melalui tahapan *data preprocessing* dan *data construction*, *dataset* selanjutnya digunakan untuk membangun model klasifikasi penyakit genetik. Pada penelitian ini, proses pemodelan dilakukan menggunakan tiga algoritma *machine learning*, yaitu Extreme Gradient Boosting (XG Boost), Random Forest, dan Support Vector Machine (SVM) dengan kernel linear. Masing-masing model terlebih dahulu dibangun menggunakan parameter awal (*default parameter*) untuk memperoleh gambaran performa dasar sebelum dilakukan proses *hyperparameter tuning*. Hasil pemodelan awal kemudian dibandingkan berdasarkan metrik evaluasi sehingga dapat diketahui model yang memiliki performa terbaik.

Selanjutnya, dilakukan pemodelan awal menggunakan algoritma XG Boost. Hasil klasifikasi model XG Boost dengan parameter awal disajikan pada Tabel 4.2 dan Gambar 4.12.

Tabel 4.2 Hasil *Classification Report* Model XG Boost *Default*

Kelas	Precision	Recall	F1-Score	Support
0	0,94	0,88	0,91	33
1	0,91	0,96	0,93	45
2	0,97	0,93	0,95	40
3	0,92	0,92	0,92	39
4	0,91	0,95	0,93	43
Macro	0,93	0,93	0,93	200
Average				
Weighted	0,93	0,93	0,93	200
Average				



Gambar 4.12 *Confusion Matrix Model XG Boost Default*


Berdasarkan Tabel 4.2, model XG Boost menunjukkan performa klasifikasi yang baik dengan nilai precision, recall, dan F1-score pada setiap kelas yang berkisar antara 0,88 hingga 0,97. Selain itu, model memperoleh nilai accuracy sebesar 93% dan nilai *Macro* ROC-AUC sebesar 0,9715, yang menunjukkan kemampuan model yang sangat baik dalam membedakan kelima kelas penyakit genetik. Nilai *weighted average* precision, recall, dan F1-score masing-masing sebesar 0,93 juga menunjukkan bahwa model memiliki performa yang konsisten pada keseluruhan data uji.

Berdasarkan Gambar 4.12, sebagian besar data berhasil diklasifikasikan dengan benar yang ditunjukkan oleh dominasi nilai pada diagonal utama *confusion matrix*. Kesalahan klasifikasi hanya terjadi pada sebagian kecil observasi dan tersebar pada beberapa kelas, sehingga tidak memberikan pengaruh yang signifikan terhadap performa model secara keseluruhan. Hasil tersebut menunjukkan bahwa model **XG Boost** dengan parameter awal telah mampu melakukan klasifikasi penyakit genetik dengan baik sebelum dilakukan proses *hyperparameter tuning*.

Selanjutnya, dilakukan pemodelan awal menggunakan algoritma Random Forest dengan parameter bawaan (*default parameter*). Hasil evaluasi model disajikan pada Tabel 4.3 berupa *classification report* dan Gambar 4.13 berupa *confusion matrix*.

Tabel 4.3 Hasil *Classification Report* Model Random Forest *Default*

Kelas	Precision	Recall	F1-Score	Support
0	0,97	0,97	0,97	33
1	0,94	1,00	0,97	45
2	1,00	0,93	0,96	40
3	0,95	0,92	0,94	39
4	0,93	0,95	0,94	43
Macro	0,96	0,95	0,96	200
Average				
Weighted	0,96	0,95	0,95	200
Average				



Gambar 4.13 *Confusion Matrix* Model Random Forest *Default*


Berdasarkan Tabel 4.3, model Random Forest menunjukkan performa klasifikasi yang sangat baik dengan nilai precision, recall, dan F1-score yang tinggi pada setiap kelas. Model memperoleh nilai accuracy sebesar 95% dan nilai *Macro* ROC-AUC sebesar 0,9722, yang menunjukkan kemampuan model yang sangat baik dalam membedakan kelima kelas penyakit genetik. Selain itu, nilai *weighted average* precision, recall, dan F1-score masing-masing sebesar 0,96, 0,95, dan 0,95, yang menunjukkan performa model yang konsisten pada keseluruhan data uji.

Berdasarkan Gambar 4.13, sebagian besar data berhasil diklasifikasikan dengan benar yang ditunjukkan oleh dominasi nilai pada diagonal utama *confusion matrix*. Kesalahan klasifikasi hanya terjadi pada sebagian kecil data, terutama pada kelas 2, 3, dan 4, sehingga tidak memberikan pengaruh yang signifikan terhadap performa model secara keseluruhan. Hasil tersebut menunjukkan bahwa model Random Forest telah mampu melakukan klasifikasi penyakit genetik dengan baik sebelum dilakukan proses *hyperparameter tuning*.

Selanjutnya, dilakukan pemodelan awal menggunakan algoritma Support Vector Machine (SVM) dengan kernel linear dan parameter bawaan (*default parameter*). Hasil evaluasi model disajikan pada Tabel 4.4 berupa *classification report* dan Gambar 4.14 berupa *confusion matrix*.

Tabel 4.4 Hasil *Classification Report* Model SVM Default

Kelas	Precision	Recall	F1-Score	Support
0	0,97	0,97	0,97	33
1	0,92	1,00	0,96	45
2	1,00	0,90	0,95	40
3	0,95	0,92	0,94	39
4	0,93	0,95	0,94	43
Macro	0,95	0,95	0,95	200
Average				
Weighted	0,95	0,95	0,95	200
Average				



Gambar 4.14 *Confusion Matrix Model SVM Default*

Berdasarkan Tabel 4.4, model Support Vector Machine (SVM) menunjukkan performa klasifikasi yang baik dengan nilai precision, recall, dan F1-score yang relatif tinggi pada setiap kelas. Model memperoleh nilai accuracy sebesar 95% dan nilai *Macro* ROC-AUC sebesar 0,9725, yang menunjukkan kemampuan model yang sangat baik dalam membedakan kelima kelas penyakit genetik. Nilai *weighted average* precision, recall, dan F1-score yang masing-masing sebesar 0,95 juga menunjukkan bahwa model memiliki performa yang konsisten pada keseluruhan data uji.


Berdasarkan Gambar 4.14, sebagian besar data berhasil diklasifikasikan dengan benar yang ditunjukkan oleh dominasi nilai pada diagonal utama *confusion matrix*. Kesalahan klasifikasi hanya terjadi pada sejumlah kecil data dan tersebar pada beberapa kelas, sehingga tidak memengaruhi performa model secara signifikan. Hasil tersebut menunjukkan bahwa model Support Vector Machine (SVM) telah mampu melakukan

klasifikasi penyakit genetik dengan baik sebelum dilakukan proses *hyperparameter tuning*.

Setelah dilakukan pemodelan awal, proses selanjutnya adalah melakukan *hyperparameter tuning* menggunakan metode GridSearchCV dengan *5-fold cross-validation*. Proses ini bertujuan untuk memperoleh kombinasi parameter yang optimal sehingga dapat meningkatkan performa model XG Boost. Berdasarkan hasil pencarian parameter, diperoleh kombinasi terbaik yaitu *colsample_bytree* sebesar 0,7, *learning_rate* sebesar 0,01, *max_depth* sebesar 7, *n_estimators* sebanyak 50, dan *subsample* sebesar 0,9. Kombinasi parameter tersebut menghasilkan nilai rata-rata akurasi *cross-validation* sebesar 95,25%, yang menunjukkan bahwa model memiliki kemampuan generalisasi yang baik terhadap data yang digunakan.

Tabel 4.5 Hasil *Classification Report* Model XG Boost *Tuning*

Kelas	Precision	Recall	F1-Score	Support
0	0,97	0,97	0,97	33
1	0,94	1,00	0,97	45
2	1,00	0,93	0,96	40
3	0,95	0,92	0,94	39
4	0,93	0,95	0,94	43
Macro	0,96	0,95	0,96	200
Average				
Weighted	0,96	0,95	0,95	200
Average				



Gambar 4.15 *Confusion Matrix Model XG Boost Tuning*


Berdasarkan Tabel 4.5, model XG Boost setelah dilakukan *hyperparameter tuning* menunjukkan peningkatan performa dibandingkan model awal. Model memperoleh nilai accuracy sebesar 95% dengan nilai *Macro* ROC-AUC sebesar 0,9780, yang menunjukkan kemampuan yang sangat baik dalam membedakan kelima kelas penyakit genetik. Selain itu, nilai *weighted average* precision, recall, dan F1-score masing-masing sebesar 0,96, 0,95, dan 0,95, sehingga menunjukkan bahwa model memiliki performa yang konsisten pada keseluruhan data uji.

Berdasarkan Gambar 4.15, sebagian besar data berhasil diklasifikasikan dengan benar yang ditunjukkan oleh dominasi nilai pada diagonal utama *confusion matrix*. Kesalahan klasifikasi hanya terjadi pada sebagian kecil data dan tersebar pada beberapa kelas sehingga tidak memberikan pengaruh yang signifikan terhadap performa model secara keseluruhan. Hasil tersebut menunjukkan bahwa penerapan *hyperparameter tuning* mampu menghasilkan model XG Boost yang memiliki kemampuan klasifikasi yang sangat baik.

Selanjutnya, proses *hyperparameter tuning* diterapkan pada algoritma Random Forest menggunakan metode GridSearchCV dengan *5-fold cross-validation*. Berdasarkan hasil pencarian parameter, diperoleh kombinasi terbaik yaitu *max_depth* sebesar 10, *max_features* menggunakan sqrt, *min_samples_leaf* sebesar 1, *min_samples_split* sebesar 5, dan *n_estimators* sebanyak 100. Kombinasi parameter tersebut menghasilkan nilai rata-rata akurasi *cross-validation* sebesar 95,63%, yang menunjukkan bahwa model memiliki kemampuan generalisasi yang baik terhadap data yang digunakan.

Tabel 4.6 Hasil *Classification Report* Model Random Forest Tuning

Kelas	Precision	Recall	F1-Score	Support
0	0,94	0,97	0,96	33
1	0,94	0,98	0,96	45
2	1,00	0,93	0,96	40
3	0,95	0,92	0,94	39
4	0,93	0,95	0,94	43
Macro	0,95	0,95	0,95	200
Average				
Weighted	0,95	0,95	0,95	200
Average				



Gambar 4.16 *Confusion Matrix* Model Random Forest *Tuning*

Berdasarkan Tabel 4.6, model Random Forest setelah dilakukan *hyperparameter tuning* memperoleh nilai accuracy sebesar 95% dengan nilai *Macro* ROC-AUC sebesar 0,9733, yang menunjukkan kemampuan yang sangat baik dalam membedakan kelima kelas penyakit genetik. Nilai *weighted average* precision, recall, dan F1-score masing-masing sebesar 0,95, 0,95, dan 0,95, sehingga menunjukkan bahwa model memiliki performa yang konsisten pada keseluruhan data uji.


Berdasarkan Gambar 4.16, sebagian besar data berhasil diklasifikasikan dengan benar yang ditunjukkan oleh dominasi nilai pada diagonal utama *confusion matrix*. Kesalahan klasifikasi masih ditemukan pada beberapa data, seperti satu data pada kelas 1 yang diprediksi sebagai kelas 0, serta beberapa kesalahan pada kelas 2, 3, dan 4. Meskipun demikian, jumlah kesalahan tersebut relatif kecil sehingga tidak memberikan pengaruh yang signifikan terhadap performa model secara keseluruhan.

Terakhir, proses *hyperparameter tuning* diterapkan pada algoritma Support Vector Machine (SVM) menggunakan metode GridSearchCV dengan *5-fold cross-*

validation. Berdasarkan hasil pencarian parameter, diperoleh kombinasi terbaik yaitu nilai C sebesar 0,1, γ menggunakan scale, dan kernel Radial Basis Function (RBF). Kombinasi parameter tersebut menghasilkan nilai rata-rata akurasi *cross-validation* sebesar 95,50%, yang menunjukkan bahwa model memiliki kemampuan generalisasi yang baik terhadap data yang digunakan.

Tabel 4.7 Hasil *Classification Report* Model SVM Tuning

Kelas	Precision	Recall	F1-Score	Support
0	0,97	0,97	0,97	33
1	0,94	1,00	0,97	45
2	1,00	0,93	0,96	40
3	0,95	0,92	0,94	39
4	0,93	0,95	0,94	43
Macro	0,96	0,95	0,96	200
Average				
Weighted	0,96	0,95	0,95	200
Average				



Gambar 4.17 *Confusion Matrix* Model SVM Tuning

Berdasarkan Tabel 4.7, model Support Vector Machine (SVM) setelah dilakukan *hyperparameter tuning* memperoleh nilai accuracy sebesar 95% dengan nilai *Macro* ROC-AUC sebesar 0,9703, yang menunjukkan kemampuan yang sangat baik dalam membedakan kelima kelas penyakit genetik. Nilai *weighted average* precision, recall, dan F1-score masing-masing sebesar 0,96, 0,95, dan 0,95, sehingga menunjukkan bahwa model memiliki performa yang konsisten pada keseluruhan data uji.

Berdasarkan Gambar 4.17, sebagian besar data berhasil diklasifikasikan dengan benar yang ditunjukkan oleh dominasi nilai pada diagonal utama *confusion matrix*. Kesalahan klasifikasi hanya terjadi pada sebagian kecil data, terutama pada kelas 2, 3, dan 4, sehingga tidak memberikan pengaruh yang signifikan terhadap performa model secara keseluruhan. Hasil tersebut menunjukkan bahwa model Support Vector Machine (SVM) setelah dilakukan *hyperparameter tuning* mampu melakukan klasifikasi penyakit genetik dengan baik.

Setelah dilakukan pemodelan menggunakan tiga algoritma, yaitu XG Boost, Random Forest, dan Support Vector Machine (SVM), baik sebelum maupun setelah *hyperparameter tuning*, langkah selanjutnya adalah membandingkan performa seluruh model untuk menentukan model terbaik. Perbandingan dilakukan berdasarkan metrik evaluasi accuracy, precision, dan Macro ROC-AUC, karena ketiga metrik tersebut mampu memberikan gambaran yang komprehensif mengenai performa model klasifikasi. Accuracy digunakan untuk mengukur proporsi prediksi yang benar terhadap seluruh data uji, precision menunjukkan ketepatan model dalam memberikan prediksi pada setiap kelas, sedangkan *Macro* ROC-AUC mengukur kemampuan model dalam membedakan seluruh kelas secara seimbang tanpa dipengaruhi oleh distribusi jumlah data pada masing-masing kelas. Hasil perbandingan performa seluruh model disajikan pada Tabel 4.8.

Tabel 4.8 Perbandingan Performa Seluruh Model

Model	Accuracy	Precision (Macro Avg)	Recall (Macro Avg)	F1-Score (Macro Avg)	Macro ROC- AUC
XG Boost (Awal)	0,930	0,93	0,93	0,93	0,9715
XG Boost (Tuning)	0,955	0,96	0,95	0,96	0,9780
Random Forest (Awal)	0,955	0,96	0,95	0,96	0,9722
Random Forest (Tuning)	0,950	0,95	0,95	0,95	0,9733
SVM (Awal)	0,950	0,95	0,95	0,95	0,9725
SVM (Tuning)	0,955	0,96	0,95	0,96	0,9703

Berdasarkan Tabel 4.8, terlihat bahwa proses *hyperparameter tuning* memberikan pengaruh yang berbeda pada setiap algoritma. Pada algoritma XG Boost, proses *hyperparameter tuning* berhasil meningkatkan seluruh metrik evaluasi, di mana nilai accuracy meningkat dari 93,0% menjadi 95,5%, precision meningkat dari 0,93 menjadi 0,96, serta nilai *Macro* ROC-AUC meningkat dari 0,9715 menjadi 0,9780. Hasil tersebut menunjukkan bahwa proses *tuning* mampu meningkatkan kemampuan model dalam melakukan klasifikasi sekaligus membedakan setiap kelas penyakit genetik.

Pada algoritma Random Forest, proses *hyperparameter tuning* tidak memberikan peningkatan performa secara keseluruhan. Meskipun nilai *Macro* ROC-AUC meningkat dari 0,9722 menjadi 0,9733, nilai accuracy justru menurun dari 95,5% menjadi 95,0%, disertai penurunan nilai precision dan F1-score. Sementara itu, pada algoritma SVM, proses *hyperparameter tuning* berhasil meningkatkan nilai accuracy dari 95,0% menjadi 95,5% serta precision dari 0,95 menjadi 0,96, namun nilai *Macro* ROC-AUC mengalami penurunan dari 0,9725 menjadi 0,9703.

Secara keseluruhan, model XG Boost setelah dilakukan *hyperparameter tuning* dipilih sebagai model terbaik pada penelitian ini. Meskipun nilai accuracy dan precision yang diperoleh sama dengan beberapa model lainnya, yaitu sebesar 95,5% dan 0,96, model ini memiliki nilai *Macro* ROC-AUC tertinggi sebesar 0,9780. Hal tersebut menunjukkan bahwa model XG Boost tidak hanya mampu menghasilkan prediksi yang akurat, tetapi juga memiliki kemampuan diskriminasi yang lebih baik dalam membedakan seluruh kelas penyakit genetik dibandingkan model lainnya. Oleh karena itu, model XG Boost setelah *hyperparameter tuning* dipilih sebagai model terbaik.

BAB V

PENUTUP

5.1 Kesimpulan

Berdasarkan hasil analisis terhadap 200 sampel data pasien yang terdistribusi secara seimbang ke dalam 5 kategori kelas penyakit genetik, proyek kami berhasil menerapkan tahapan prapemrosesan data yang komprehensif, mulai dari business understanding, data understanding, *preprocessing*, data *construction*, dan *modeling*. Melalui implementasi dan komparasi tiga algoritma *machine learning* utama yaitu XG Boost, SVM, dan Random Forest, ditemukan bahwa model XG Boost yang dikombinasikan dengan skenario hyperparameter tuning merupakan algoritma dengan performa terbaik dan paling optimal. Model ini tidak hanya mencetak tingkat akurasi tertinggi sebesar 95.5% dan nilai F1-Score sebesar 96%, melainkan juga terbukti paling unggul dalam menggeneralisasi data serta memisahkan antar-kelas penyakit berkat capaian nilai ROC AUC tertinggi yang menyentuh angka 0.978041. Tingginya akurasi klasifikasi dalam mendeteksi jenis penyakit genetik ini didorong secara signifikan oleh variabel klinis tertentu dan indikator medis spesifik pasien, yang terekam memiliki skor kontribusi terbesar berdasarkan hasil analisis kepentingan fitur (*feature importance*) pada model.

5.2 Saran

Berdasarkan hasil yang dicapai dalam proyek *machine learning* ini, disarankan untuk pengembangan proyek ke depan agar dapat memperluas cakupan *dataset* dengan menambah jumlah sampel pasien serta mengintegrasikan variasi fitur klinis yang lebih kaya guna menguji ketahanan model pada skenario data riil yang lebih kompleks. Selain itu, proses eksperimen dapat ditingkatkan dengan mengeksplorasi teknik optimasi hiperparameter yang lebih otomatis seperti Bayesian Optimization, atau mencoba arsitektur deep learning untuk melihat potensi peningkatan performa klasifikasi yang lebih tinggi. Mengingat model XG Boost (*Tuning*) terbukti memberikan performa paling optimal dan stabil, model ini sangat direkomendasikan untuk melakukan deployment ke dalam sistem berbasis web atau aplikasi seluler

sebagai prototipe alat bantu skrining awal penyakit genetik yang dapat membantu efisiensi kerja tenaga medis di masa mendatang.

LAMPIRAN

Link dataset : <https://www.kaggle.com/datasets/syeddanish5/genetic-disease-prediction-dataset>

Link Collab

: <https://colab.research.google.com/drive/1Skw1bN0Lv2UIPkbV8UtDKLozhqVFO3Kn?usp=sharing>

Link Github : [azradita30-art/PROJECT-ML](https://github.com/azradita30-art/PROJECT-ML)

